

Previsão multi-horizonte do preço do ouro: uma comparação entre modelos lineares, **boosting** e redes neurais profundas sobre log-retornos

Francisco Paulino Arruda Filho
Ivina Lorena Oliveira Moura
Gabriel de Souza Mendes
José Vinícius Evangelista Dias de Souza

{paulinofilho, ivinalorena, gabrielmendes01,
joseedsouza}@alu.ufc.br

Sumário

1 Motivação

2 Dados e Reformulação

3 Protocolo e EDA

4 Modelos e Métricas

5 Resultados e Discussão

6 Conclusão

Por que o ouro é difícil de prever?

- O ouro funciona como **ativo de reserva** e **hedge**: reage a inflação, crises geopolíticas, juros reais e força do dólar.
- Isso torna a dinâmica do preço sensível a **choques macroeconômicos** e mudanças de regime.
- Em horizontes curtos, o sinal preditível é **fraco** e fica imerso em ruído de mercado.
- Mesmo quando existe algum padrão, ele tende a ser **marginal** e instável ao longo do tempo.

Tensão central do trabalho: pode existir sinal útil, mas ele é pequeno o bastante para ser facilmente confundido com acaso ou vazamento de informação.

Não-estacionariedade e extrapolação

- O preço saiu de cerca de **US\$ 280/onça** em 2000 para mais de **US\$ 3000/onça** em 2025.
- O nível da série muda demais ao longo do tempo: a média não é estável.
- Um modelo treinado no **preço bruto** não vê, no treino, os mesmos patamares que aparecem no teste.
- Isso vira um problema de **extrapolação**, não apenas de previsão.

Preço diário do ouro (2000–2025)



Figura 1: Preço de fechamento diário do ouro entre 2000 e 2025.

Mercado eficiente e **random walk**

Ponto de partida

Se os mercados incorporam rapidamente a informação disponível, o melhor palpite para o preço de amanhã é o preço de hoje [1].

- Esse é o raciocínio do **random walk**: mudanças de curto prazo são próximas de imprevisíveis.
- A série pode ter memória de regimes e tendência em horizontes maiores, mas o ruído domina no dia a dia.
- Por isso, bater um **baseline** ingênuo já é um critério forte de qualidade.

O desafio não é só prever bem; é demonstrar que o ganho é real e não ilusão estatística.

Nossa primeira tentativa (que falhou)

- A hipótese inicial era simples: **se enriquecermos bem os dados, um bom modelo aprende o preço do ouro.**
- Em um experimento anterior (2025), foi usada **Ridge Regression** para prever o preço **1 dia à frente**.
- O código desse experimento ficou disponível em:

<https://github.com/JoseEdSouza/machine-learning-works/blob/main/gold/eda.ipynb>

Moral inicial: o problema parecia ser “escolher um modelo melhor”, mas a falha principal estava na formulação e no protocolo.

Onde o experimento anterior errou

- Antes do **split**, as amostras foram embaralhadas com **shuffle** aleatório.
- Isso mistura observações do passado e do futuro entre treino e teste.
- Em séries temporais, esse procedimento gera **vazamento temporal**.
- O modelo parece aprender muito bem, mas parte desse desempenho vem de uma avaliação contaminada.
- Resultado: **overfitting** otimista e uma noção falsa de generalização.

Conclusão

O erro central não era só o modelo. Era tentar prever o **preço bruto** sob um protocolo de avaliação quebrado.

Os dados

- **Fonte:** **Precious Metals History since 2000 with News**, disponível no Kaggle [2].
- **Período:** 2000–2025, com frequência diária.
- **Colunas principais:** OHLC (**open, high, low, close**), volume e **headlines**.
- A coluna **headlines** reúne, para cada pregão, manchetes associadas àquela data, vindas de diferentes jornais/fontes noticiosas.
- **Alvo:** log-retorno acumulado para $h \in \{5, 15, 30\}$ pregões.
- O problema deixa de ser prever nível de preço e passa a ser prever variação futura acumulada.

Como construímos a feature textual

- Se a coluna `headlines` existe, o texto é convertido para minúsculas e valores ausentes viram string vazia.
- Em seguida, contamos ocorrências de um léxico de termos de estresse:
 - `crisis, crash, war, recession, inflation, default, collapse, panic, fear, conflict, sanction, bankrupt, plunge, turmoil, slump, selloff, attack, invasion, pandemic, virus`
- O índice principal é:

$$\text{fear_ratio} = \frac{\text{\#termos do léxico}}{\text{\#separadores "/" nas manchetes} + 1}$$

- Depois calculamos `fear_ma5`, uma média móvel de 5 dias desse índice.

Intuição: quanto mais palavras associadas a crise e pânico aparecem nas manchetes do pregão, maior o sinal textual de medo.

Atributos de entrada ($d = 19$)

Tabela 1: Atributos de entrada do modelo. Todos são causais e invariantes ao nível de preço.

Atributo	Definição	Grupo
log_ret_1,5,21	$\log(P_t/P_{t-k})$, $k \in \{1, 5, 21\}$	Momentum
vol_5, vol_21	desvio-padrão móvel de log_ret_1	Volatilidade
vol_ratio	$\text{vol}_5/\text{vol}_{21}$ (> 1 = estresse)	Volatilidade
dist_ma20,50	$P_t/\text{MA}_k - 1$, $k \in \{20, 50\}$	Tendência
ma_cross	$\text{MA}_{20}/\text{MA}_{50} - 1$	Tendência
rsi	RSI(14) recentrado em $[-1, 1]$	Oscilador
macd_hist	histograma MACD normalizado por P_t	Oscilador
boll_b	posição %B nas bandas de Bollinger	Oscilador
drawdown_252	$P_t/\max_{252}(P) - 1$	Regime
hl_range	$(\text{high} - \text{low})/P_t$	Intradiário
close_pos	posição do fechamento na barra OHLC	Intradiário
gap_open	$\log(\text{open}_t/P_{t-1})$	Intradiário
volume	volume negociado no dia	Liquidez
fear_ratio	índice de medo por léxico nas manchetes	Texto
fear_ma5	média móvel de 5 dias de fear_ratio	Texto

Todos os atributos são causais e invariantes ao nível de preço.

O que tentamos antes de reformular o problema

- Depois de identificar os erros, treinamos primeiro um **baseline** ingênuo para ter uma referência honesta.
- Ficou claro que parte central da dificuldade vinha da inflação empurrando o nível do preço para cima ao longo do tempo.
- Também testamos sinais exógenos e textuais para enriquecer os dados antes de mexer no alvo.
- A lição foi direta: **enriquecer os dados no espaço errado não resolve o problema estrutural.**

A virada conceitual do trabalho veio quando deixamos de insistir no preço bruto e passamos a reformular o alvo.

Inflação (CPI)

- A hipótese era que o CPI ajudaria a explicar a tendência persistente de alta do ouro.
- Na prática, a contribuição foi marginal.
- Há um problema operacional importante: índices de inflação são calculados e divulgados com atraso.
- Se esse atraso não for tratado explicitamente, surge risco de **look-ahead bias** e vazamento temporal.

Decisão: descartado. O custo metodológico e o risco de vazamento eram maiores do que o ganho observado.

Petrodólar

- A hipótese era que ouro e petróleo capturam, em parte, o mesmo estresse geopolítico e macroeconômico.
- Em alguns períodos a correlação aparecia, mas ela não era estável ao longo do tempo.
- Isso introduziu complexidade extra de alinhamento entre séries e regimes.
- O ganho prático foi pequeno demais para justificar a complexidade adicional.

Decisão: descartado. Relação plausível economicamente, mas fraca e inconsistente para o protocolo adotado.

Embeddings das manchetes

- Testamos embeddings `nomic-embed-text` (768 dimensões) como entrada para um XGBoost.
- O resultado piorou de forma significativa em relação ao XGBoost baseline.
- A interpretação mais provável é combinação de pouco dado útil com alta dimensionalidade.
- Embeddings da OpenAI, como `text-embedding-3-small` e `text-embedding-3-large`, ficaram no **roadmap**, mas não houve tempo de avaliação adequada.

Leitura correta

Não concluímos que texto não ajuda. Concluímos apenas que esse caminho exige mais tempo, melhor representação e experimentação mais cuidadosa.

Moral desse bloco

- Baseline honesto primeiro.
- Variáveis externas mal alinhadas podem criar mais vazamento do que sinal.
- Mais atributos não significam melhor generalização.
- O avanço real veio de **reformular o alvo**, não de empilhar sinais sobre o preço bruto.

A reformulação: parar de prever o preço

- Em vez de prever o **preço bruto**, passamos a prever o **log-retorno acumulado**.
- Para cada instante t , o alvo passa a ser:

$$y_t^{(h)} = \log\left(\frac{P_{t+h}}{P_t}\right), \quad h \in \{5, 15, 30\}. \quad (1)$$

- Ou seja: a pergunta deixa de ser “qual será o preço futuro?” e passa a ser “qual será a variação acumulada nos próximos 5, 15 e 30 pregões?”.

Ideia central: mudamos a pergunta, não o modelo.

Por que o log-retorno funciona melhor?

- O log-retorno é **aproximadamente estacionário** e tende a ficar centrado em zero.
- Isso evita o problema de extrapolar para níveis de preço nunca vistos no treino.
- Ele também é **aditivo e simétrico**, o que facilita a modelagem temporal.
- Depois da previsão, o preço pode ser reconstruído por:

$$\hat{P}_{t+h} = P_t \cdot \exp(\hat{y}_t^{(h)}). \quad (2)$$

- Assim, modelamos na escala estatisticamente adequada e avaliamos novamente em US\$/oz.

Mudando a pergunta

Antes

Prever diretamente o preço bruto de um ativo não-estacionário.

- forte tendência
- extrapolação difícil
- avaliação enganosa

Depois

Prever retornos acumulados em múltiplos horizontes.

- série mais estável
- alvo comparável no tempo
- avaliação mais honesta

Regressão multi-horizonte

- Cada entrada passa a ser uma janela de **60 pregões** com atributos causais.
- A saída do modelo são **três previsões simultâneas**: $h = 5$, $h = 15$ e $h = 30$.
- Isso enquadra o problema como **regressão multi-horizonte**.
- A arquitetura pode compartilhar representação temporal e aprender padrões úteis para horizontes curtos e longos ao mesmo tempo.

Entrada: janela de 60 dias $\longrightarrow$ Saídas: $\{\hat{y}^{(5)}, \hat{y}^{(15)}, \hat{y}^{(30)}\}$

Protocolo de avaliação

- O **split** principal é **estritamente temporal**: 70% treino, 15% validação e 15% teste.
- Não há **shuffle**.
- Entre os conjuntos, inserimos um **gap de 90 pregões** para evitar sobreposição entre janelas e alvos.
- Esse gap vem de $L + \max(h) = 60 + 30 = 90$.

Divisão temporal com gap anti-vazamento



Figura 2: Divisão temporal treino/validação/teste com gap anti-vazamento.

Por que esse split é desafiador?

- A crise de **2008** fica no treino.
- A pandemia de **2020** aparece na validação.
- O forte **rally** de **2021–2025** fica no teste.
- Ou seja: o teste cobra generalização em um regime recente e em patamares de preço muito mais altos.

Leitura correta: o protocolo não facilita o problema. Ele força o modelo a enfrentar mudança de regime sem vazamento temporal.

Split único vs. **walk-forward**

Split único

- um treino
- uma validação
- um teste final

Bom para comparação direta entre modelos.

Walk-forward

- treino expansivo
- folds anuais
- embargo entre treino e teste

Bom para medir robustez em vários regimes.

Ideia: o split único responde “quem foi melhor neste re-corte?”; o **walk-forward** responde “quem sustenta desempenho ao longo do tempo?”

Validação **walk-forward**

- Depois do **split** principal, usamos validação **walk-forward** como checagem honesta de robustez.
- Cada **fold** usa **treino expansivo** e um bloco de teste de aproximadamente **252 pregões** (cerca de 1 ano).
- Entre treino e teste, há **embargo** para impedir contaminação temporal.
- Isso produz uma distribuição de desempenho ao longo de anos e regimes diferentes, em vez de um único número.

EDA: confirmando que o problema é duro

- A análise exploratória foi usada para testar se a série trazia sinal estatístico simples ou apenas ruído.
- O resultado foi consistente com a dificuldade esperada para séries financeiras.
- Os log-retornos exibem caudas pesadas, pouca autocorrelação linear e forte agrupamento de volatilidade.
- Em outras palavras: há estrutura, mas ela não é fácil de capturar com modelos ingênuos.

Distribuição dos log-retornos




Figura 3: Histograma, Q-Q plot e boxplot dos log-retornos diários do ouro.

Os log-retornos são **leptocúrticos**, com **caudas pesadas e assimetria negativa**.

ADF: preço vs. log-retorno

Série	Resultado ADF	Interpretação
Preço do ouro	não rejeita raiz unitária	não-estacionária
Log-retorno diário	rejeita raiz unitária	aproximadamente estacionária

A evidência estatística reforça a decisão de modelar **retornos**, e não o **preço bruto**.

ACF e PACF dos log-retornos




Figura 4: ACF e PACF dos log-retornos do ouro.

A autocorrelação linear é **fraca** e, em grande parte, **não significativa**.

Volatility clustering




Figura 5: Volatilidade anualizada com janela móvel de 21 dias.

As crises de **2008** e **2020** concentram picos de volatilidade, evidenciando **volatility clustering**.

Os modelos: do mais simples ao mais complexo




Figura 6: Visão geral dos modelos avaliados, do mais simples ao mais complexo.

Modelos de referência




Figura 7: Modelos de referência: **random walk** e regressão linear.

Modelos de referência

Random walk

Piso absoluto: a previsão para $t + h$ é simplesmente o preço atual P_t .

Regressão linear

- baseline treinável mais simples;
- usa a mesma janela temporal dos demais modelos;
- a janela 60×19 é achatada em **1140 regressores**.

Se modelos mais sofisticados não superarem essas referências, a complexidade extra não se justifica.

XGBoost




Figura 8: Visão geral do modelo XGBoost.

XGBoost

- Primeiro modelo não linear forte do trabalho.
- Implementado como **gradient boosting** de árvores [3].
- Treinado **separadamente por horizonte** ($h = 5, 15, 30$).
- Hiperparâmetros ajustados com **otimização bayesiana** e validação cruzada temporal.
- Funciona bem com dados tabulares e interações não lineares entre atributos.

Intuição: cada árvore corrige parte do erro das anteriores, acumulando um modelo mais expressivo que a regressão linear.

GRU




Figura 9: Visão geral do modelo GRU.

LSTM




Figura 10: Visão geral do modelo LSTM.

GRU e LSTM

- São modelos **recorrentes**: processam a janela de 60 dias passo a passo.
- Capturam dependências temporais de forma explícita.
- No trabalho, GRU e LSTM compartilham a mesma ideia de arquitetura:
 - duas camadas recorrentes;
 - normalização e **dropout**;
 - **3 cabeças de saída** multitarefa para $h = 5, 15, 30$.
- A LSTM é mais expressiva; a GRU é mais enxuta em número de parâmetros.

CNN 1D causal




Figura 11: Visão geral da CNN 1D causal com dilatação.

CNN 1D causal: modelo champion

- Modelo principal do trabalho.
- Usa **convoluções causais** com dilatação crescente:
 $1 \rightarrow 2 \rightarrow 4$.
- Essa dilatação amplia o campo receptivo e permite cobrir 60 dias com poucas camadas.
- A saída combina **pooling** médio e máximo global antes das cabeças multitarefa.
- Tamanho: **110.979 parâmetros treináveis**.

Intuição: a CNN enxerga padrões locais e de médio alcance sem precisar percorrer a sequência inteira passo a passo como uma RNN.

Configuração final dos modelos neurais

Tabela 2: Configuração final dos modelos neurais avaliados.

Hiperparâmetro	CNN 1D	GRU / LSTM
Camadas extratoras	$3 \times$ Conv1D causal	$2 \times$ recorrente (64)
Filtros / unidades	96, 64, 256	64, 64
Dilatação / kernel	$1 \rightarrow 2 \rightarrow 4$ / 5,3,3	—
Spatial Dropout	0,20	0,15
Densa + Dropout	64 / 0,20	64 / 0,25
Taxa de aprendizado	$4,1 \times 10^{-3}$	$1,0 \times 10^{-3}$
Pesos da perda	1,0 / 0,6 / 0,2	1,0 / 0,7 / 0,5
Épocas / batch	120 / 64	120 / 64
Early stopping	paciência 15	paciência 15
Parâmetros treináveis	110.979	$\approx 60\text{--}80$ mil

Extensão: CNN por quantis

- Extensão do modelo principal para prever **quantis** em vez de um único valor.
- Saídas: q_{10} , q_{50} , q_{90} para cada horizonte.
- Função de perda: **pinball loss**, adequada para regressão quantílica [4].
- Aplicação principal: validação **walk-forward** com **intervalos de incerteza**.

Ganho prático: em vez de uma estimativa pontual aparentemente precisa, o modelo comunica uma faixa plausível de preço futuro ($p_{10}p_{90}$).

Métricas

- A avaliação principal usa duas métricas centrais:
 - **MAE/MAE_{naive}**: compara o erro do modelo com o erro do **random walk**;
 - **acurácia direcional**: mede quantas vezes o modelo acertou o sinal do retorno.
- Essas são métricas **honestas** porque respondem à pergunta prática: o modelo realmente superou uma referência ingênua?
- Valores de **MAE/MAE_{naive}** **abaixo de 1** indicam ganho real sobre o baseline.

Por que essas métricas são mais honestas?

MAE/MAE_{naive}

0,95

erro 5% menor que o
random walk

Acurácia direcional

62%

acerto no sentido
da variação

Ideia: não basta errar pouco em dólares; é preciso bater a previsão ingênua e acertar a direção do movimento.

Alerta: R^2 no preço pode enganar

Parece ótimo

$$R^2 = 0,98$$

na escala de preço

Mas pode empatar

$$\text{MAE/naive} = 1,0$$

mesmo desempenho do
random walk

Gancho para a discussão: um R^2 altíssimo no preço pode ser só reflexo da tendência da série, sem ganho preditivo real.

Split único: três achados principais

- A **regressão linear** não bate o **random walk** de forma consistente.
- **CNN 1D** e **XGBoost** superam o baseline ingênuo em **todos os horizontes**.
- O ganho fica mais claro em horizontes longos: em $h = 30$, ambos chegam a cerca de **62%** de acurácia direcional.

Leitura: no recorte de teste único, há sinal útil, mas ele é pequeno e aparece mais nitidamente quando o horizonte aumenta.

Desempenho no split único

Tabela 3: Desempenho dos modelos no split único cronológico, por horizonte.

<i>h</i>	Modelo	MAE	RMSE	MAPE (%)	Dir. (%)	MAE/naive
5	Regressão Linear	38,23	48,20	1,82	52,5	1,160
	XGBoost	32,53	41,62	1,56	56,5	0,987
	GRU	32,65	41,77	1,57	53,4	0,990
	LSTM	32,62	41,50	1,57	53,3	0,989
	CNN 1D	32,39	41,42	1,56	57,4	0,983
15	Regressão Linear	63,87	80,22	3,05	55,0	1,068
	XGBoost	58,26	73,11	2,78	58,9	0,974
	GRU	59,56	74,36	2,84	56,5	0,996
	LSTM	58,48	73,23	2,78	54,8	0,978
	CNN 1D	58,08	72,68	2,77	58,9	0,971
30	Regressão Linear	87,66	109,09	4,16	58,4	1,002
	XGBoost	83,16	101,45	3,89	62,0	0,951
	GRU	85,00	103,70	3,97	58,7	0,972
	LSTM	85,77	103,49	4,02	57,6	0,980
	CNN 1D	83,43	102,38	3,92	62,0	0,954

Curvas de aprendizado da CNN




Figura 12: Curvas de treino e validação da CNN principal.

Preço real vs. previsto




Figura 13: Preço real e previsto pela CNN em $h = 5$, $h = 15$ e $h = 30$.

E se o split de teste só deu sorte?

**E se o split de teste só
deu sorte?**

Walk-forward: a virada honesta

- Quando avaliamos com **walk-forward**, o quadro fica bem menos otimista.
- A vantagem média sobre o **random walk** fica **próxima de 1,0**.
- O desvio entre **folds** é alto, principalmente em $h = 30$.
- Ou seja: o ganho existe em alguns regimes, mas **não é estável** ao longo do tempo.

Leitura correta: o split único mostrava um caso favorável; o walk-forward revela a robustez real do método.

Validação walk-forward

Tabela 4: Desempenho médio $\pm$ desvio-padrão dos modelos neurais na validação walk-forward.

Modelo	h	Dir. (%)	MAE/naive
CNN 1D	5	55,3 $\pm$ 5,7	0,995 $\pm$ 0,024
	15	54,8 $\pm$ 8,4	1,006 $\pm$ 0,055
	30	54,8 $\pm$ 13,9	1,037 $\pm$ 0,138
GRU	5	51,5 $\pm$ 2,0	1,042 $\pm$ 0,038
	15	53,9 $\pm$ 6,6	1,047 $\pm$ 0,067
	30	58,1 $\pm$ 12,1	1,074 $\pm$ 0,225
LSTM	5	51,4 $\pm$ 4,0	1,048 $\pm$ 0,047
	15	55,1 $\pm$ 4,5	1,049 $\pm$ 0,068
	30	55,9 $\pm$ 10,7	1,075 $\pm$ 0,193

Boxplots no walk-forward




Figura 14: Distribuição das métricas da CNN entre folds no walk-forward.

Por que isso acontece?

- O desempenho depende fortemente do **regime de mercado**.
- Em anos de tendência forte, os modelos conseguem capturar direção.
- Em mercados laterais e ruidosos, o sinal praticamente desaparece.

Frase-chave: os modelos capturam tendência quando ela existe, mas não “criam” sinal onde ele não existe.

Desempenho por ano em $h = 30$




Figura 15: Acurácia direcional e MAE/naive por ano calendário para a CNN em $h = 30$.

Leitura por regime

- Em anos de tendência, como **2021**, **2024** e **2025**, a acurácia direcional passa de **80%** e o MAE/naive cai abaixo de **0,85**.
- Em mercados laterais, como **2022** e **2023**, a acurácia cai para algo como **46–48%**, isto é, **pior que o acaso**.
- Isso explica por que o split único parecia forte, mas o walk-forward mostrou instabilidade.

R^2 alto pode ser ilusão




Figura 16: Dispersão entre preço previsto e preço real no teste para a CNN.

Ponto central: mesmo com R^2 entre 0,92 e 0,98, o ganho real sobre o **random walk** pode ser apenas marginal.

Quem foi mais estável?

- No **split** único, CNN 1D e XGBoost praticamente empatam entre os melhores.
- No **walk-forward**, a **CNN** fica mais estável e com média mais próxima de ganho real consistente.
- GRU e LSTM ficam mais sensíveis à variação entre regimes.
- Por isso, a CNN 1D causal foi escolhida como **modelo principal** do trabalho.

Heatmap de acurácia direcional em $h = 30$




Figura 17: Acurácia direcional por modelo e por ano em $h = 30$.

Onde os modelos falham

- O heatmap deixa claro que **2022** e **2023** são anos difíceis para todos os modelos.
- Esses períodos são mais laterais e ruidosos, com pouco sinal direcional persistente.
- O índice de medo por léxico ajuda pouco: a informação textual ainda está subexplorada.
- Isso reforça a leitura final do trabalho: **os modelos capturam tendência quando ela existe, mas não “criam” sinal.**

Conclusão

- **Primeiro achado:** reformular o problema em **log-retorno** foi essencial para torná-lo estatisticamente bem posto.
- **Segundo achado:** no **split** recente, **CNN 1D** e **XGBoost** superam o **random walk**.
- **Terceiro achado:** sob validação **walk-forward**, esse ganho fica pequeno e dependente do regime.

Mensagem final: o trabalho mostra que existe sinal preditivo marginal, mas ele é frágil e não sobrevive de forma uniforme a todos os cenários de mercado.

Limitações

- O sinal direcional é intrinsecamente **fraco**.
- O estudo foi feito sobre **um único ativo** e um **único período histórico**.
- O componente textual foi tratado de forma **rudimentar**, com um léxico simples de medo.
- Portanto, os resultados não devem ser lidos como solução geral para previsão financeira.

Trabalhos futuros

- Substituir o léxico de medo por **embeddings** ou modelos de **sentimento financeiro**.
- Incorporar variáveis macroeconômicas causais, como **juros reais, dólar e outros metais**.
- Avaliar arquiteturas com atenção, como o **Temporal Fusion Transformer**.
- Fazer **calibração formal** dos intervalos previstos pela CNN por quantis.

O caminho promissor não é só aumentar a complexidade do modelo, mas enriquecer causalmente a informação e medir melhor a incerteza.

Referências I

- [1] Eugene F. Fama. “Efficient Capital Markets: A Review of Theory and Empirical Work”. Em: **The Journal of Finance** 25.2 (1970), pp. 383–417.
- [2] Kaggle. **Precious Metals History since 2000 with News**. <https://www.kaggle.com/datasets/romanfonel/precious-metals-history-since-2000-with-news>. Dataset online. 2025.
- [3] Tianqi Chen e Carlos Guestrin. “XGBoost: A Scalable Tree Boosting System”. Em: **Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining**. 2016, pp. 785–794.
- [4] Roger Koenker e Gilbert Bassett. “Regression Quantiles”. Em: **Econometrica** 46.1 (1978), pp. 33–50.

Obrigado(a) pela Atenção!

Contato:

{paulinofilho, ivinalorena, gabrielmendes01,
joseedsouza}@alu.ufc.br